

Exercícios em computador

C1 Os dados do arquivo 401K são um subconjunto de dados analisados por Papke (1995) para estudar a relação entre a participação em um plano de pensão 401k e a generosidade do plano. A variável `prate` é a porcentagem de trabalhadores aptos e com uma conta ativa; esta é a variável que gostaríamos de explicar. A medida da generosidade é a taxa de contribuição do plano, `mrte`. Esta variável mostra a quantia média com que a empresa contribui para o fundo trabalhista a cada US\$ 1 de contribuição do trabalhador. Por exemplo, se a `mrte` = 0,50, então uma contribuição de US\$ 1 do trabalhador corresponde a uma contribuição de US\$ 0,50 da empresa.

```
library(wooldridge)
data("k401k")
```

(i) Encontre a taxa de participação e a taxa de contribuição médias na amostra de planos.

```
mean(k401k$prate) # media taxa de participacao
```

```
## [1] 87.36291
```

```
mean(k401k$mrte) # media taxa de contribuicao
```

```
## [1] 0.7315124
```

(ii) Agora, estime a equação de regressão simples, e relate os resultados ao lado do tamanho da amostra e do R-quadrado.

$$\widehat{prate} = \hat{\beta}_0 + \hat{\beta}_1 mrte$$

```
model <- lm(prate ~ mrte, data = k401k)
summary(model) # resultados
```

```
##
## Call:
## lm(formula = prate ~ mrte, data = k401k)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -82.303  -8.184   5.178  12.712  16.807
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   83.0755     0.5633  147.48  <2e-16 ***
## mrte          5.8611     0.5270   11.12  <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
##
## Residual standard error: 16.09 on 1532 degrees of freedom
## Multiple R-squared:  0.0747, Adjusted R-squared:  0.0741
## F-statistic: 123.7 on 1 and 1532 DF,  p-value: < 2.2e-16
```

(iii) Interprete o intercepto de sua equação. Interprete o coeficiente de `mrte`.

O intercepto $\beta_0 = 83,07$ indica o valor esperado ou estimado de `prate` quando `mrte` é igual a zero. Já o coeficiente β_1 indica que existe uma relação positiva entre `mrte` e `prate`, e que também a cada unidade acrescida de `mrte` estima-se um aumento em `prate` de 5,86 unidades.

(iv) Encontre a `prate` prevista quando `mrte` = 3,5. Esta é uma previsão razoável? Explique o que está ocorrendo aqui.

$$\widehat{prate} = 83,07 + 5,86 * 3,5$$

```
83.07 + (5.86 * 3.5)
```

```
## [1] 103.58
```

Este valor é impossível, dado que a taxa máxima de participação é de 100%. Isto ilustra que, especialmente quando as variáveis dependentes são limitadas, um modelo de regressão simples pode fornecer previsões estranhas para valores extremos da variável independente. Na amostra, existem apenas 34 valores de `mrte` maiores ou iguais a 3,5.

(v) Quanto da variação da `prate` é explicada pela `mrte`? Na sua opinião, isso é bastante?

Aproximadamente 7,4% da variação de `prate` é explicada por `mrte`. Este não é um valor alto, indicando que provavelmente existem outros fatores que influenciam a taxa de participação.

C2 O conjunto de dados do arquivo CEOSAL2 contém informações sobre CEOs de corporações norte-americanas. A variável `salary` é a compensação anual, em milhares de dólares, e `ceoten` é o número prévio de anos como CEO da empresa.

```
library(wooldridge)
data("ceosal2")
```

(i) Encontre o salário médio e a permanência média na amostra.

```
mean(ceosal2$salary) # salario medio
```

```
## [1] 865.8644
```

```
mean(ceosal2$ceoten) # permanencia media
```

```
## [1] 7.954802
```

(ii) Quantos CEOs estão em seu primeiro ano no cargo (isto é, $ceoten = 0$)? Qual é a permanência mais longa como CEO?

```
max(subset(ceosal2, ceoten == 0)$comten) # permanencia mais longa quando ceoten igual a 0
```

```
## [1] 33
```

(iii) Estime o modelo de regressão simples e registre seus resultados da forma usual. Qual é o aumento percentual previsto (aproximado) no salário quando se tem um ano a mais como CEO?

$$\log(\text{salary}) = \beta_0 + \beta_1 \text{ceoten} + \mu$$

```
model <- lm(lsalary ~ ceoten, data = ceosal2) # estimando modelo
summary(model) # resultados
```

```
##
## Call:
## lm(formula = lsalary ~ ceoten, data = ceosal2)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -2.15314 -0.38319 -0.02251  0.44439  1.94337
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  6.505498   0.067991  95.682  <2e-16 ***
## ceoten       0.009724   0.006364   1.528   0.128
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.6038 on 175 degrees of freedom
## Multiple R-squared:  0.01316,    Adjusted R-squared:  0.007523
## F-statistic: 2.334 on 1 and 175 DF,  p-value: 0.1284
```

$$\widehat{\log(\text{salary})} = 6,5055 + 0,0097 * \text{ceoten}$$

$$n = 177, \quad R^2 = 0,01316$$

Um aumento de um ano a mais como CEO gera um aumento no salário em 0,97%.

C3 Use os dados do arquivo SLEEP75, de Biddle e Hamermesh (1990), para estudar se há uma compensação entre o tempo gasto dormindo por semana e o tempo gasto em um trabalho remunerado. Podemos usar qualquer variável como a variável dependente. Para materializar, estime o modelo

$$\text{sleep} = \beta_0 + \beta_1 \text{totwrk} + u,$$

em que **sleep** são os minutos dormidos à noite por semana e **totwrk** é o total de minutos trabalhados durante a semana.

```
library(wooldridge)
data("sleep75")
```

```
model <- lm(sleep ~ totwrk, data = sleep75) # estimando modelo
summary(model) # resultados
```

```
##
## Call:
## lm(formula = sleep ~ totwrk, data = sleep75)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -2429.94  -240.25    4.91   250.53  1339.72
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  3586.37695   38.91243   92.165  <2e-16 ***
## totwrk       -0.15075    0.01674   -9.005  <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 421.1 on 704 degrees of freedom
## Multiple R-squared:  0.1033, Adjusted R-squared:  0.102
## F-statistic: 81.09 on 1 and 704 DF, p-value: < 2.2e-16
```

(i) Registre seus resultados em uma equação junto com o número de observações e o R^2 . O que o intercepto desta equação significa?

$$\widehat{sleep} = 3586,38 - 0,15 * totwrk$$

$$n = 706, \quad R^2 = 0,1033$$

O intercepto da equação indica os minutos dormidos por semana quando a quantidade de minutos trabalhados na semana, totwrk for igual a zero.

(ii) Se totwrk aumentar 2 horas, quanto você estima que sleep cairá? Você acha que este é um efeito grande?

```
model$coefficients[2] * 2 * 60 # totwrk é medido em horas, portanto precisa fazer a conversão

##      totwrk
## -18.0895
```

Um aumento de duas horas de trabalho na semana, reduzirá em 18 minutos dormidos durante a semana. Isso não parece ser um valor muito alto.

C4 Use os dados do arquivo WAGE2 para estimar uma regressão simples que explique o salário mensal (wage) em termos da pontuação do QI (IQ).

```
library(wooldridge)
data("wage2")
```

(i) Encontre o salário médio e o IQ médio da amostra. Qual é o desvio padrão amostral do IQ? (Pontuações de IQ são padronizadas, por isso, a média na população é 100 com um desvio padrão igual a 15.)

```
mean(wage2$wage) # salário médio
```

```
## [1] 957.9455
```

```
mean(wage2$IQ) # IQ médio
```

```
## [1] 101.2824
```

```
sd(wage2$IQ) # desvio-padrão de IQ
```

```
## [1] 15.05264
```

(ii) Estime um modelo de regressão simples em que um aumento de um ponto em IQ altere wage em uma quantia constante de dólares. Use este modelo para encontrar o aumento previsto do salário para o caso de um acréscimo de 15 pontos de IQ. O IQ explica a maior parte da variação em wage?

```
model <- lm(wage ~ IQ, data = wage2) # estimando o modelo
summary(model) # resultados
```

```
##
## Call:
## lm(formula = wage ~ IQ, data = wage2)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -898.7  -256.5  -47.3   201.1  2072.6
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  116.9916    85.6415   1.366   0.172
## IQ           8.3031     0.8364   9.927 <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 384.8 on 933 degrees of freedom
## Multiple R-squared:  0.09554,    Adjusted R-squared:  0.09457
## F-statistic: 98.55 on 1 and 933 DF,  p-value: < 2.2e-16
```

$$\widehat{salary} = 116,9 + 8,30(IQ)$$

$$n = 935, \quad R^2 = 0,09554$$

Um aumento de 15 no IQ aumenta o salário mensal previsto em $8,30 \cdot (15) = \$124,50$ (em dólares de 1980). A pontuação de IQ não explica nem 10% da variação salarial.

(iii) Agora, estime um modelo em que cada acréscimo de um ponto em IQ tenha o mesmo efeito percentual em wage. Se IQ aumentar 15 pontos, qual será o aumento percentual previsto aproximado em wage?

```
model <- lm(lwage ~ IQ, data = wage2) # estimando modelo
summary(model)

##
## Call:
## lm(formula = lwage ~ IQ, data = wage2)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -2.09324 -0.25547  0.02261  0.27544  1.21487
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  5.8869944  0.0890206   66.13  <2e-16 ***
## IQ           0.0088072  0.0008694   10.13  <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.3999 on 933 degrees of freedom
## Multiple R-squared:  0.09909,    Adjusted R-squared:  0.09813
## F-statistic: 102.6 on 1 and 933 DF,  p-value: < 2.2e-16
```

$$\log(\widehat{salary}) = 5,89 + 0,008(IQ)$$

$$n = 935, \quad R^2 = 0,09$$

Se variar em 15 então $\Delta \log(\text{salário}) = 0,0088(15) = 0,132$, que é a mudança proporcional (aproximada) no salário previsto. O aumento percentual é, portanto, de aproximadamente 13,2.

C5 Para a população de empresas do setor químico, defina **rd** como os gastos anuais em pesquisa e desenvolvimento, e **sales** como as vendas anuais (ambos em milhões de dólares).

(i) Escreva um modelo (não uma equação estimada) que implique uma elasticidade constante entre **rd** e **sales**. Qual é o parâmetro da elasticidade?

$$\log(rd) = \beta_0 + \beta_1(sales) + \mu$$

- β_1 é a elasticidade de **rd** em relação a **sales**

(ii) Agora, estime o modelo usando os dados do arquivo RDCHEM. Monte a equação estimada da forma usual. Qual é a elasticidade estimada de rd em relação a sales? Explique o que essa elasticidade significa.

```
library(wooldridge)
data("rdchem")

model <- lm(lrd ~ lsales, data = rdchem) # estimando modelo
summary(model)

##
## Call:
## lm(formula = lrd ~ lsales, data = rdchem)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.90406 -0.40086 -0.02178  0.40562  1.10439
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) -4.10472     0.45277  -9.066 4.27e-10 ***
## lsales       1.07573     0.06183  17.399 < 2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.5294 on 30 degrees of freedom
## Multiple R-squared:  0.9098, Adjusted R-squared:  0.9068
## F-statistic: 302.7 on 1 and 30 DF,  p-value: < 2.2e-16
```

A elasticidade estimada de rd em relação à sales é de 1,076. Estima-se que um aumento de um por cento nas vendas aumente os gastos em pesquisa e desenvolvimento em cerca de 1,08%.

C6 Usamos os dados do arquivo MEAP93 no Exemplo 2.12. Agora, queremos explorar a relação entre a taxa de aprovação em matemática (math10) e os gastos por estudante (expend).

```
library(wooldridge)
data("meap93")
```

(i) Você acha que cada dólar adicional gasto tem o mesmo efeito sobre a taxa de aprovação ou um efeito decrescente seria mais razoável? Explique.

A taxa de aprovação deve crescer a taxas decrescentes, ou seja, quanto maior a taxa de aprovação, maior será o gasto necessário para aumentar a taxa de aprovação na mesma unidade.

(ii) No modelo populacional, argumente que $\beta_1/10$ é a porcentagem de alteração em math10 dado um aumento de 10% em gasto.

$$\text{math10} = \beta_0 + \beta_1 \log(\text{expend}) + \mu$$

Ceteris paribus, a variação de math10 é dada por

$$\begin{aligned}\Delta \text{math10} &= \beta_1 \Delta \log(\text{expend}) \\ \Delta \text{math10} &\approx \frac{\beta_1}{100} (\% \Delta \text{expend})\end{aligned}$$

Portanto, para uma variação de 10% em gasto, $\% \Delta \text{expend} = 10$

$$\Delta \text{math10} \approx \frac{\beta_1}{100} \times 10 \approx \frac{\beta_1}{10}$$

(iii) Use os dados do arquivo MEAP93 para estimar o modelo (ii). Descreva a equação estimada da forma usual, incluindo o tamanho da amostra e o R-quadrado.

```
model <- lm(math10 ~ lexpend, data = meap93) # estimando modelo
summary(model)

##
## Call:
## lm(formula = math10 ~ lexpend, data = meap93)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -22.343  -7.100  -0.914   6.148  39.093
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  -69.341     26.530  -2.614  0.009290 **
## lexpend       11.164       3.169   3.523  0.000475 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 10.35 on 406 degrees of freedom
## Multiple R-squared:  0.02966,    Adjusted R-squared:  0.02727
## F-statistic: 12.41 on 1 and 406 DF,  p-value: 0.0004752
```

$$\begin{aligned}\widehat{\text{math10}} &= -69,341 + 11,164 \log(\text{expend}) \\ n &= 608, \quad R^2 = 0,02966\end{aligned}$$

(iv) Quão grande é o efeito de gastos estimado? Em outras palavras, se os gastos aumentarem 10%, qual será o aumento percentual estimado em math10 ?

Se aumentarmos os gastos em 10%, math10 aumentará em 1,1% aproximadamente. Este efeito é maior quando consideramos escolas com um gasto baixo.

(v) Alguns podem se preocupar com o fato de que a análise de regressão pode produzir valores ajustados para math10 maiores do que 100. Por que isso não é tão preocupante neste conjunto de dados?


```
subset(meap93, math10 > 100) # quantidade de observações maiores do que 100
```

```
## [1] lchprg enroll staff expend salary benefits droprate gradrate  
## [9] math10 sci11 totcomp ltotcomp lexpend lenroll lstaff bensal  
## [17] lsalary  
## <0 rows> (or 0-length row.names)
```

```
max(meap93$math10) # valor máximo de math10 na base de dados
```

```
## [1] 66.7
```

```
max(model$fitted.values) # valor máximo de math ajustado no modelo
```

```
## [1] 30.15375
```

Isso é preocupante pois não existem observações no conjunto de dados com valores para math10 maiores do que 100.

C7 Use os dados do arquivo CHARITY [retirado de Franses e Paap (2001)] para responder às seguintes questões:

```
library(wooldridge)  
data("charity")
```

(i) Qual é a doação (gift) média da amostra de 4.268 pessoas (em florins holandeses)? Qual é a porcentagem de pessoas com nenhuma doação?

```
mean(charity$gift) # doação média
```

```
## [1] 7.44447
```

```
mean(charity$gift == 0) # porcentagem de pessoas com nenhuma doação
```

```
## [1] 0.6000469
```

(ii) Qual é a média de envios por ano? Quais são os valores mínimos e máximos?

```
mean(charity$mailsyear) # media de envios por ano
```

```
## [1] 2.049555
```

```
min(charity$mailsyear) # valor mínimo
```

```
## [1] 0.25
```

```
max(charity$mailsyear) # valor máximo
```

```
## [1] 3.5
```

(iii) Estime o modelo por MQO e registre os resultados da forma usual, incluindo o tamanho da amostra e o R-quadrado.

$$gift = \beta_0 + \beta_1 mailsyear + \mu$$

```
model <- lm(gift ~ mailsyear, data = charity) # estimando modelo
summary(model)
```

```
##
## Call:
## lm(formula = gift ~ mailsyear, data = charity)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -11.287   -7.976   -5.976    2.687   245.999
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)    2.0141     0.7395   2.724  0.00648 **
## mailsyear      2.6495     0.3431   7.723  1.4e-14 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 14.96 on 4266 degrees of freedom
## Multiple R-squared:  0.01379,    Adjusted R-squared:  0.01356
## F-statistic: 59.65 on 1 and 4266 DF,  p-value: 1.404e-14
```

$$\widehat{gift} = 2,0141 + 2,6495(mailsyear)$$
$$n = 4268, \quad R^2 = 0,01379$$

(iv) Interprete o coeficiente de inclinação. Se cada envio custa um florim, a instituição de caridade espera obter um lucro líquido em cada um dos envios? Isso quer dizer que a instituição obtém um lucro líquido em todos os envios? Explique.

O coeficiente de inclinação indica que cada envio por ano está associado a cerca de 2,65 florins adicionais, em média. Portanto, se cada envio custa um florim, o lucro esperado de cada envio é estimado em 1,65 florins. Esta é apenas a média, no entanto. Algumas correspondências não geram contribuições ou geram uma contribuição inferior ao custo da correspondência, outras correspondências geraram muito mais do que o custo da correspondência.

(v) Qual é a menor contribuição à instituição prevista na amostra? Usando essa análise de regressão simples, você pode prever zero de gift?

Como o menor ano de correspondência na amostra é 0.25, o menor valor previsto de presentes é $2,01 + 2,65(0,25) \approx 2,67$. Mesmo se olharmos para a população em geral, onde algumas pessoas não receberam qualquer correspondência, o menor valor previsto é cerca de dois. Portanto, com esta equação estimada, nunca prevemos zero doações de caridade.

C8

C9

C10